

TÀI LIỆU KIỂM THỬ ONTOLOGY-AWARE RAG

Tài liệu do project tạo để kiểm tra PDF ingestion, chunking, retrieval, query expansion, Ontology-aware re-ranking và citation. Không sử dụng số liệu từ tài liệu này làm kết quả nghiên cứu chính thức.

1. BM25 và tìm kiếm từ khóa

BM25 là một thuật toán xếp hạng tài liệu dựa trên từ khóa. Thuật toán xem xét tần suất xuất hiện của từ trong đoạn văn, độ hiếm của từ trong toàn bộ tập tài liệu và độ dài của đoạn. Những từ hiếm nhưng xuất hiện đúng trong truy vấn thường đóng góp nhiều hơn vào điểm xếp hạng. Đây là một mô hình lexical retrieval có cơ sở xác suất.

Ưu điểm của BM25 là nhanh, nhẹ và dễ giải thích. Hạn chế chính là phương pháp này không hiểu tốt từ đồng nghĩa hoặc những cách diễn đạt khác nhau. Ví dụ, truy vấn 'xe hơi' có thể không khớp với đoạn chỉ dùng từ 'ô tô'.

2. Semantic Search và embedding

Semantic Search tìm kiếm theo ý nghĩa thay vì chỉ so sánh từ khóa. Câu hỏi và các chunk được chuyển thành vector embedding bằng một mô hình Sentence Transformers. Các vector gần nhau thể hiện nội dung có ý nghĩa tương tự.

Cosine similarity được dùng để đo độ gần giữa vector câu hỏi và vector chunk. Nhờ đó, hệ thống có thể tìm được một đoạn nói về ô tô khi người dùng hỏi về xe hơi. Hạn chế là semantic search đôi khi chọn đoạn có ý nghĩa chung gần giống nhưng thiếu thuật ngữ chính xác cần thiết.

3. Hybrid Search và Reciprocal Rank Fusion

Hybrid Search kết hợp BM25 với Semantic Search để tận dụng cả từ khóa chính xác và sự tương đồng về ý nghĩa. Mỗi bộ tìm kiếm tạo ra một bảng xếp hạng chunk độc lập.

Reciprocal Rank Fusion, viết tắt là RRF, kết hợp các bảng xếp hạng dựa trên vị trí của từng chunk. Một chunk đứng cao ở cả BM25 và Semantic Search sẽ nhận điểm RRF tốt. RRF không yêu cầu điểm BM25 và cosine similarity phải có cùng thang đo.

4. Retrieval-Augmented Generation

Retrieval-Augmented Generation, viết tắt là RAG, tìm các đoạn bằng chứng trước khi mô hình ngôn ngữ tạo câu trả lời. Các chunk liên quan cùng metadata nguồn được đưa vào prompt để giới hạn ngữ cảnh của mô hình.

Một hệ thống RAG có kiểm soát phải trả lời dựa trên evidence được cung cấp và kèm citation gồm tên tài liệu, số trang và chunk ID. Nếu evidence không đủ để kết luận, hệ thống phải thông báo chưa đủ thông tin thay vì tự suy đoán.

5. QASPER và đánh giá evidence

QASPER là một bộ dữ liệu hỏi đáp trên các bài báo khoa học. Mỗi câu hỏi được liên kết với câu trả lời và các đoạn bằng chứng trong bài báo, vì vậy dữ liệu này phù hợp để đánh giá retrieval và question answering.

Evidence F1 đo mức độ trùng khớp giữa bằng chứng hệ thống chọn và bằng chứng chuẩn. Citation Precision đo tỷ lệ citation thực sự chứa thông tin hỗ trợ cho câu trả lời. Hai chỉ số giúp phân biệt câu trả lời có căn cứ với câu trả lời chỉ nghe hợp lý.

6. Ontology và Knowledge Graph

Ontology định nghĩa các lớp khái niệm và quan hệ trong miền tri thức. Trong hệ thống hỏi đáp tài liệu, các lớp chính có thể gồm Paper, Section, Chunk, Task, Method, Dataset và Metric. Knowledge Graph chứa các instance và liên kết thực tế được tạo theo cấu trúc Ontology.

Ontology hỗ trợ query expansion bằng synonym, superclass, subclass và related concept. Sau Hybrid Search, Ontology-aware re-ranking tăng điểm cho chunk chứa concept có quan hệ gần với concept của câu hỏi. OntoScore ghi nhận mức phù hợp ngữ nghĩa có cấu trúc này. Trong ontology mẫu, Question Answering là một nhánh của Natural Language Processing; Information Retrieval có các nhánh Keyword Search, Semantic Search và Hybrid Search.

7. AI Agent và kiểm tra bằng chứng

AI Agent điều phối các công cụ của hệ thống. Agent nhận câu hỏi, xác định truy vấn, gọi retrieval, yêu cầu Ontology mở rộng hoặc xếp hạng lại, rồi chuyển evidence phù hợp cho mô hình ngôn ngữ.

Trước khi trả lời, Agent phải kiểm tra evidence có hỗ trợ kết luận hay không. Câu trả lời cuối cùng phải kèm filename, page và chunk ID. Nếu không tìm được evidence đủ tốt, Agent từ chối trả lời để hạn chế hallucination.

8. Các chỉ số đánh giá retrieval

Precision at k đo tỷ lệ kết quả đúng trong k chunk đầu tiên. Recall at k đo tỷ lệ bằng chứng đúng đã được tìm thấy trong k kết quả đầu tiên. Mean Reciprocal Rank, viết tắt là MRR, đánh giá vị trí của kết quả đúng đầu tiên.

Normalized Discounted Cumulative Gain, hay nDCG, đánh giá chất lượng của toàn bộ thứ tự xếp hạng và ưu tiên kết quả đúng ở vị trí cao. Đồ án so sánh BM25, Semantic, Hybrid và Hybrid kết hợp Ontology trên cùng một tập câu hỏi và gold evidence.

9. TF-IDF và so khớp từ vựng

TF-IDF cũng xếp hạng văn bản từ tần suất và độ hiếm của từ. Khác với BM25, công thức TF-IDF cơ bản không có cùng cơ chế bão hòa tần suất và chuẩn hóa độ dài. Vì cùng thuộc nhóm lexical retrieval, hai phương pháp thường trả về các đoạn có nhiều từ giống câu hỏi.

So khớp từ vựng rất hữu ích với mã sản phẩm, tên riêng và thuật ngữ chính xác, nhưng dễ bỏ sót một câu diễn đạt cùng ý bằng từ khác. Trang này là dữ liệu gây nhiễu cho các câu hỏi về BM25 và tìm kiếm theo từ khóa.

10. Phân cụm vector

Phân cụm vector nhóm các điểm gần nhau trong không gian embedding mà không cần nhãn có sẵn. K-means có thể được dùng để khám phá chủ đề hoặc tổ chức kho tài liệu, nhưng bản thân việc phân cụm không phải là thao tác truy xuất một chunk cho câu hỏi.

Khoảng cách cosine xuất hiện trong cả phân cụm và tìm kiếm ngữ nghĩa. Việc cùng dùng vector và cosine có thể khiến một hệ thống chọn nhầm trang này khi câu hỏi thực sự hỏi cách Semantic Search truy hồi nội dung tương đồng.

11. Hợp nhất điểm số tuyến tính

Một cách kết hợp kết quả là chuẩn hóa điểm BM25 và điểm semantic rồi cộng theo trọng số. Phương pháp weighted score fusion nhạy với cách chuẩn hóa vì hai bộ tìm kiếm có thang điểm khác nhau.

Cách này không phải Reciprocal Rank Fusion. RRF chỉ sử dụng vị trí trong từng bảng xếp hạng, còn hợp nhất tuyến tính sử dụng trực tiếp giá trị điểm. Trang này tạo một đối chứng gần nghĩa cho chủ đề Hybrid Search.

12. Mô hình ngôn ngữ không có truy hồi

Một mô hình ngôn ngữ có thể tạo câu trả lời chỉ từ tham số đã học mà không đọc tài liệu của người dùng. Cách làm này tạo văn bản trôi chảy nhưng nguồn kiến thức khó kiểm soát và có nguy cơ tạo thông tin không có căn cứ.

Khác với RAG, quy trình này không lấy evidence trước khi sinh câu trả lời và không thể gắn citation đến filename, page, chunk ID trong kho tài liệu. Đây là trang gây nhiễu cho câu hỏi về tạo sinh và hallucination.

13. Bộ dữ liệu SQuAD

SQuAD là bộ dữ liệu hỏi đáp đọc hiểu gồm câu hỏi và đoạn văn từ Wikipedia. Dữ liệu được dùng rộng rãi để đánh giá khả năng trích xuất câu trả lời từ một ngữ cảnh cho trước.

SQuAD cũng thuộc bài toán question answering nhưng không phải QASPER. QASPER tập trung vào bài báo khoa học và gắn câu hỏi với evidence trong tài liệu nghiên cứu. Hai bộ dữ liệu gần nhau về nhiệm vụ nhưng khác miền và cấu trúc bằng chứng.

14. Taxonomy và danh sách nhãn

Taxonomy sắp xếp thuật ngữ theo cấu trúc cha con để hỗ trợ phân loại. Một danh sách nhãn phẳng chỉ ghi tên các chủ đề mà không mô tả đầy đủ ngữ nghĩa giữa chúng.

Ontology rộng hơn taxonomy vì có thể định nghĩa class, property, instance và nhiều loại quan hệ như synonym hoặc related concept. Knowledge Graph dùng cấu trúc đó để lưu các sự kiện cụ thể về tài liệu và chunk.

15. Chatbot theo kịch bản

Chatbot theo kịch bản chọn câu trả lời từ các luật if-then hoặc một cây hội thoại được viết trước. Nó có thể điều hướng người dùng nhưng không tự lập kế hoạch dùng các công cụ retrieval, Ontology và mô hình ngôn ngữ.

AI Agent khác chatbot luật ở khả năng điều phối nhiều bước, quan sát kết quả công cụ và quyết định có đủ evidence hay chưa. Hai hệ thống đều nhận câu hỏi nên dễ bị nhầm nếu truy vấn chỉ nói chung về trợ lý hỏi đáp.

16. Độ chính xác của câu trả lời

Answer accuracy đánh giá nội dung câu trả lời cuối cùng có đúng hay không. Chỉ số này thuộc giai đoạn generation và không trực tiếp cho biết gold chunk được xếp ở vị trí nào trong danh sách retrieval.

Đánh giá retrieval cần các chỉ số riêng như Precision at k, Recall at k, MRR và nDCG. Một hệ thống có thể tìm đúng evidence nhưng vẫn tạo câu trả lời sai, hoặc trả lời hợp lý dù citation không thực sự hỗ trợ kết luận.