

TÀI LIỆU MẪU VỀ RAG

Dùng để kiểm tra chức năng đọc PDF, chia đoạn và tìm kiếm BM25 trong project.

Mục tiêu thử nghiệm

Sau khi tải tài liệu này vào API, hệ thống phải nhận biết nội dung, giữ đúng số trang và trả về đoạn văn liên quan khi người dùng tìm kiếm từ khóa.

1. RAG là gì?

RAG là viết tắt của Retrieval-Augmented Generation. Thay vì yêu cầu mô hình ngôn ngữ trả lời hoàn toàn bằng kiến thức đã học, hệ thống tìm các đoạn tài liệu liên quan trước. Những đoạn này trở thành ngữ cảnh để mô hình tạo câu trả lời chính xác và có nguồn tham chiếu.

2. Vì sao phải chia tài liệu thành chunk?

Một tài liệu dài không nên được đưa toàn bộ vào mô hình. Project chia văn bản thành các chunk khoảng 180 từ. Mỗi chunk chồng lấn 40 từ với chunk kế tiếp để hạn chế việc một ý quan trọng bị cắt ở ranh giới. Kích thước chunk là tham số cần thử nghiệm theo loại tài liệu.

3. Tìm kiếm BM25

BM25 là thuật toán xếp hạng dựa trên từ khóa. Nó ưu tiên đoạn chứa từ khóa hiếm và phù hợp với câu truy vấn. BM25 nhanh, nhẹ và dễ giải thích, nhưng chưa hiểu tốt từ đồng nghĩa hoặc những câu diễn đạt khác với tài liệu gốc.

TỪ RETRIEVAL ĐẾN CÂU TRẢ LỜI

4. Semantic search và embedding

Semantic search biến câu hỏi và các chunk thành vector embedding. Những vector gần nhau thể hiện nội dung có ý nghĩa tương tự, kể cả khi không dùng đúng cùng một từ khóa. Project có thể kết hợp BM25 và embedding thành hybrid search để tăng độ bao phủ.

5. Vai trò của FastAPI

FastAPI cung cấp các endpoint cho ứng dụng. Endpoint POST /documents nhận PDF, trích xuất văn bản và lập chỉ mục. Endpoint GET /search nhận câu truy vấn rồi trả về tên file, số trang, nội dung chunk và điểm liên quan. Giao diện Swagger tại /docs hỗ trợ kiểm tra API.

6. Các giới hạn cần xử lý

Chỉ mục hiện lưu trong RAM nên sẽ mất khi server khởi động lại. PDF scan chỉ chứa hình ảnh cần OCR mới đọc được. Hệ thống thực tế còn phải giới hạn kích thước file, kiểm tra định dạng, quản lý nhiều người dùng và lưu vector trong PostgreSQL với pgvector.

7. Hallucination và trích dẫn

Hallucination xảy ra khi mô hình tạo thông tin không có căn cứ. Một pipeline RAG tốt phải yêu cầu mô hình chỉ trả lời từ ngữ cảnh tìm được, hiển thị nguồn và số trang, đồng thời thừa nhận khi tài liệu không chứa đủ thông tin để trả lời.

Gợi ý truy vấn thử

BM25 là gì? • chunk overlap dùng để làm gì? • FastAPI có vai trò gì? • hallucination là gì?